

EXERCICE I. PERCEPTRON (RÉSEAU FEED-FORWARD À UNE COUCHE DE POIDS)

Considérons un réseau de neurones qui consiste à un neurone de sortie avec son taux de décharge y , et D neurones d'entrée avec ses taux de décharge $\vec{x} = (x_1, \dots, x_D)$. Le neurone d'entrée avec l'index i est connecté au neurone de sortie avec un poids synaptique w_i . Tous les poids forment le vecteur des poids $\vec{w} = (w_1, \dots, w_D)$. La fonction d'activation est sigmoïde,

$g(a) = (1 + e^{-a})^{-1}$, où $a = w_0 + \sum_{i=1}^D w_i x_i = w_0 + \vec{w} \cdot \vec{x}$ est l'activation du neurone de sortie. Ici, le paramètre w_0 correspond au poids synaptique d'une entrée fixe $x_0 = 1$ (appelé “le biais”).

On interprète ce réseau de neurones comme une machine de classification de données:

- considérons un jeu de données dans D dimensions, c'est-à-dire un ensemble de vecteurs (souvent appelés “motifs”) $\{\vec{x}^{(1)}, \vec{x}^{(2)}, \dots, \vec{x}^{(N)}\}$, où chacun des motifs $\vec{x}^{(p)} = (x_1^{(p)}, x_2^{(p)}, \dots, x_D^{(p)})$, $p = 1, 2, \dots, N$. Géométriquement, un motif correspond à un point dans D dimensions.
- on choisie un motif $\vec{x}^{(p)}$, on l'introduit au réseau et on calcule la valeur de sortie $y(\vec{x}^{(p)})$
- si $y \leq 0.5$, on classifie le motif comme appartenant à la classe A. Dans le cas contraire on assigne le motif à la classe B.
- application du réseau à tous les motifs donne lieu à une séparation de l'ensemble des données en deux classes.

A. Réseau dans une dimension ($D = 1$).

1. Exprimer y en fonction de x_1 (avec w_0 et w_1 comme paramètres de cette fonction).
2. Trouver la valeur de x_1 qui correspond à la frontière entre deux classes (point d'inflexion de la sigmoïde).
3. Trouver la pente de $y(x_1)$ au point d'inflexion.
4. Pour deux motifs arbitraires (par ex. $x_1^{(1)} = 2$ et $x_1^{(2)} = 6$) proposer les poids synaptiques w_0 et w_1 pour que le réseau classifie $x_1^{(1)}$ à la classe A et $x_1^{(2)}$ à la classe B.
5. Tracer la courbe $y(x_1)$ correspondant à w_0 et w_1 de l'étape précédente.

B. Réseau dans deux dimensions ($D = 2$).

1. Exprimer y en fonction de \vec{x} et \vec{w} .
2. La frontière entre les classes A et B vérifie la condition $y = 0.5$ (Expliquer pourquoi). Trouver l'équation de cette frontière en termes de x_1 et x_2 . Conclusion ?
3. Démontrer que le vecteur des poids \vec{w} est perpendiculaire à la frontière
4. Démontrer que la distance perpendiculaire entre la frontière et l'origine est égale à $-\frac{w_0}{\|\vec{w}\|}$
5. On choisie $w_0 = -1$ et $\vec{w} = (1, 1)$. Sur le plan (x_1, x_2) représenter le vecteur de poids \vec{w} et la frontière entre les classes. Que se passe-t-il si l'on change la direction de \vec{w} , en gardant la norme constant? Que se passe-t-il si l'on change w_0 , en gardant \vec{w} fixe ? Quelle est la forme de la fonction $y(x_1, x_2)$?
6. Comment les résultats si-dessus généralisent-ils à la dimension $D > 2$?

EXERCICE II. APPRENTISSAGE : RÈGLE DELTA

On considère le réseau de neurones de l'exercice I. L'erreur totale de classification pour l'ensemble des données $\{\vec{x}^{(1)}, \vec{x}^{(2)}, \dots, \vec{x}^{(N)}\}$ peut être calculée selon la formule suivante :

$$E(\vec{w}) = \sum_{p=1}^N E^{(p)} = \sum_{p=1}^N \frac{1}{2} (y^{(p)} - t^{(p)})^2 \text{ où :}$$

- $E^{(p)}$ est l'erreur de classification d'un seul motif $\vec{x}^{(p)}$.
- $t^{(p)}$ est l'étiquette du motif $\vec{x}^{(p)}$; $t^{(p)} = 0$ si $\vec{x}^{(p)}$ appartient à la classe A, et $t^{(p)} = 1$ si $\vec{x}^{(p)}$ appartient à la classe B.

L'erreur totale est une fonction des poids $\vec{w} = (w_1, \dots, w_D)$. Classification correcte de tous les motifs correspond au minimum de l'erreur ($E(\vec{w}) = 0$), i.e. quand la réponse du réseau $y^{(p)}$ est égale à l'étiquette de la classe $t^{(p)}$ pour tous les motifs.

Apprentissage du réseau correspond à la minimisation de la fonction d'erreur dans l'espace des poids (w_1, \dots, w_D) par la méthode de descente de gradient. Selon cette méthode, le changement d'un poids synaptique w_i après la présentation d'un motif $\vec{x}^{(p)}$, est proportionnel à la dérivée négative de E :

$$\Delta w_i = -\eta \frac{\partial E^{(p)}}{\partial w_i}$$

A. Démontrer que

$$\Delta w_i = -\eta \delta x_i^{(p)} \quad (\text{"delta-rule"})$$

où

$$\delta = g'(a)(y^{(p)} - t^{(p)}) \quad (\text{"delta-error"})$$

B. Démontrer que

$$g'(a) = g(a)(1 - g(a))$$

EXERCICE III. APPRENTISSAGE : ALGORITHME DE RÉTROPROPAGATION DU GRADIENT

On considère un réseau avec un neurone de sortie et deux couches de poids, dans D dimensions (voir les diapos du cours). La sortie du réseau :

$$y = \sum_{j=0}^H w_j^{(2)} z_j$$

où $w_j^{(2)}$ est le poids synaptique entre le neurone de sortie et le $j^{\text{ème}}$ neurone cachés, dont le taux de décharge est égal à (sauf le neurone biais pour lequel $z_0 = 1$):

$$z_j = g\left(\sum_{i=1}^D w_{ji}^{(1)} x_i\right)$$

où $w_{ji}^{(1)}$ est le poids entre $j^{\text{ème}}$ neurone caché et $i^{\text{ème}}$ neurone d'entrée.

Démontrer que la méthode de descente de gradient de l'exercice précédent correspond aux formules suivantes pour la mise à jour des poids :

$$\Delta w_j^{(2)} = -\eta \delta z_j \quad \text{où} \quad \delta = y^{(p)} - t^{(p)}$$

et

$$\Delta w_{ji}^{(1)} = -\eta \delta_j x_i \quad \text{où} \quad \delta_j = g'(a_j) w_j^{(2)} \delta$$

EXERCICE IV. PLUSIEURS NEURONES DE SORTIE

On ajoute au réseau de l'exercice I.B deux neurones de sortie, on a alors

$$y_k = g(a_k), \quad k = 0, 1, 2$$

$$a_k = w_{k0} + \sum_{i=1}^D w_{ki} x_i, \quad D = 2.$$

Dans ce réseau, chaque neurone de sortie encode l'appartenance à une classe : y_0 code pour la classe A, y_1 code pour la classe B, et y_2 code pour la classe C (on a toujours autant de classes que de neurones de sortie).

Apprentissage : on introduit un motif $\vec{x}^{(p)}$, calcule le vecteur de sortie $\vec{y} = (y_0, y_1, y_2)$ et applique la méthode de descente de gradient avec les étiquettes de la forme suivante: $\vec{t} = (1, 0, 0)$ si $\vec{x}^{(p)}$ appartient à la classe A, $\vec{t} = (0, 1, 0)$ si $\vec{x}^{(p)} \in B$, et $\vec{t} = (0, 0, 1)$ si $\vec{x}^{(p)} \in C$.

Si l'on considère chaque neurone de sortie comme un sous-réseau (identique au réseau de l'exercice I.B), on voit que $k^{\text{ème}}$ neurone de sortie est entraîné pour distinguer les motifs de sa classe ($y_k = 1$) de toute les autres motifs ($y_k = 0$).

Classification : pour classifier un motif \vec{x} , on l'introduit au réseau, on calcule $\vec{y} = (y_0, y_1, y_2)$. On dit que le motif appartient à la classe avec l'activité maximale, par ex. à la classe B si $y_1 > y_0$ et $y_1 > y_2$.

- Exprimer y_0 , y_1 et y_2 en fonction de x_1 et x_2 .
- Quelle condition est vérifiée sur la frontière entre les classes A et B ? Quelle est l'équation de cette frontière en termes de x_1 et x_2 ?
- La même question pour la frontière entre B et C et entre A et C.
- Comment les résultats si-dessus généralisent-ils à la dimension $D > 2$?
- Démontrer que la règle d'apprentissage a la forme suivante :

$$\Delta w_{ki} = -\eta \delta_k x_i^{(p)} \quad (\text{"delta-rule"})$$

$$\delta_k = g'(a_k)(y_k^{(p)} - t_k^{(p)}) \quad (\text{"delta-error"})$$